LAPORAN PENGGANTI UAS MK KECERDASAN BUATAN

DIKUMPULKAN PADA: 28 DESEMBER 2022

Nama Mahasiswa : Muhammad Aidan Daffa Junaidi

NPM : 1906300800

Judul Paper : Optic-Net: A Novel Convolutional Neural Network for Diagnosis of Retinal Diseases from Optical

Tomography Images

Penulis : Sharif Amit Kamran, Sourajit Saha, Ali Shihab Sabbir, dan Alireza Tavakkoli

Dipublikasikan di : Cornell University Library, arXiv.org

Tahun : 2019

Modality/Alat Pencitraan: Optical Coherence Tomography (OCT)

Task/Tujuan pengolahan : Mendiagnosis berbagai penyakit retina dari gambar Spectral Domain Optical Coherence

Tomography (SD-OCT).

Bahasa Pemrograman : Python

Link Paper : https://arxiv.org/pdf/1910.05672v1.pdf
Link Source Code : https://github.com/SharifAmit/OpticNet-71

RESUME PAPER

1 PENDAHULUAN

Jelaskan dalam Bahasa Indonesia:

a) latar belakang masalah/topik penelitian yang diangkat,

Mendesain aristektur algoritma CNN yang mampu mendiagnosis beberpa penyakit retina dari gambar Spectral Domain Optical Coherence Tomography (SD-OCT) secara optimal.

b) urgensi topik penelitian,

Saat ini berbagai pendekatan dengan image processing, machine learning, dan algoritma deep learning telah digunakan untuk mendeteksi dan mendiagnosis penyakit retina. Sayangnya, pendekatan – pendekatan ini masih rentan terhadap kesalahan (error) dan ketidakefisienan komputasi, yang hasilnya masih memerlukan intervensi lebih lanjut dari pakar manusia. Didalam paper yang digunakan umtuk tugas ini, diusulkan arsitektur CNN baru yang berhasil membedakan antara berbagai degenerasi lapisan retina dan penyebab dasarnya. Yang hasilnnya akan memperbagus akurasi.

c) metode-metode terkini (state-of-the-art) yang telah dihasilkan oleh peneliti lain yang disebutkan dalam paper tsb,

No mor refe rens i	Penulis	Judul Paper	Metode yang diusulka n	Kelebiha n yang diusung	Celah/Ke kurangan
6	K. Alsaih, G. Lemaitre, M. Rastgoo, J. Massich, D. Sidibe, dan F. Meriaudeau	Machi ne learnin g techni ques for diabeti c macula r edema (dme) classifi cation	Menggu nakan generic pipelinet ermasuk preproce ssing, deteksi fitur, represen tasi fitur, dan klasifikas i	Selain memban dingkan fitur individu dan gabunga n, pendeka tan represen tasi yang berbeda dan pengklas	Dataset relatif sedikit, accuracy masih bisa ditingkat kan, belum menggun akan arsitektur deep learning

		T	I	:	1
		on sd- oct		ifikasi yang	
		images		berbeda	
				juga	
				dievalua	
				si	
		"Auto			
		mated			
		detecti			
		on of			
		exudat ive			
		age-			
		related	Terdapat healthy		
		macula	control		
		r	group	11	
		degen eration	dalam	Hasil dari	Hanya
		in	menyiap	evaluasi	mendete
26	M. Treder, J. L. Lauermann, and N. Eter	spectr	kan data	metric	ksi
		al	dan menggun	sangat	penyakit AMD
		domai	akan	bagus	, ((V))
		n	Deep		
		optical cohere	Learning		
		nce	CNN		
		tomog			
		raphy			
		using			
		deep learnin			
		g			
		Classifi			
		cation		Penerap	
		of sd-	Monagu	an VGG	Dataset
		oct	Menggu nakan	berhail meningk	relatif sedikit ,
2.4	AA Assais II Mullan T D Tasas and 5 Manias days	images	algoritm	atkan	Metric
34	M. Awais, H. Muller, T. B. Tang, and F. Meriaudeau	using a deep	a CNN,	metric	evaluasi
		learnin	arsitektu	evaluasi	masih
		g	r VGG 16	SE	terbilang
		approa		sebesar 20%	kecil
		ch		2070	
		Transf			
		er	Menggu	penggun	
		learnin	nakan	aan	
		g based	algoritm	model	D-1
		classifi	a CNN, arsitektu	pre- trained	Dataset relatif
		cation	r	untuk	sedikit ,
		of	GoogLeN	konverg	Metric
35	S. P. K. Karri, D. Chakraborty, and J. Chatterjee	optical	et dan	ensi	evaluasi
		cohere nce	menggun	yang	masih
		tomog	akan	lebih	bisa
		raphy	transfer learning	cepat dengan	ditingkat kan
		images	dari	lebih	Aun
		with	imagene	sedikit	
		diabeti	t	data	
		c macula			
<u></u>		macuid			

	r edema and dry age- related macula r degen eration		
https://openaccess.thecvf.com/content_cvpr_2017/papers/Ch_ ollet_Xception_Deep_Learning_CVPR_2017_paper.pdf			

d) ide utama dari metode yang penulis usulkan,

Penulis mengusulkan arsitektur baru yang mengungguli model klasifikasi lain sambil menangani masalah *gradient explosion*. Pendekatan yang penulis lakukan mencapai akurasi hampir sempurna 99,8% dan 100% untuk dua set data Retinal SD-OCT yang tersedia secara terpisah. penulis mengusulkan jaringan CNN yang berspesialisasi dalam mengidentifikasi penyakit retina dengan presisi yang hampir sempurna.

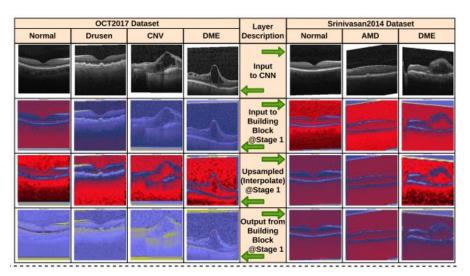
e) tujuan penelitian/kontribusi/kebaruan yang ditawarkan.

Melalui arsitektur ini penulis mengusulkan (a) unit residu baru yang memasukkan Atrous Separable Convolution, (b) building block baru dan (c) mekanisme untuk mencegah degradasi gradien.

2 METODE YANG DITAWARKAN

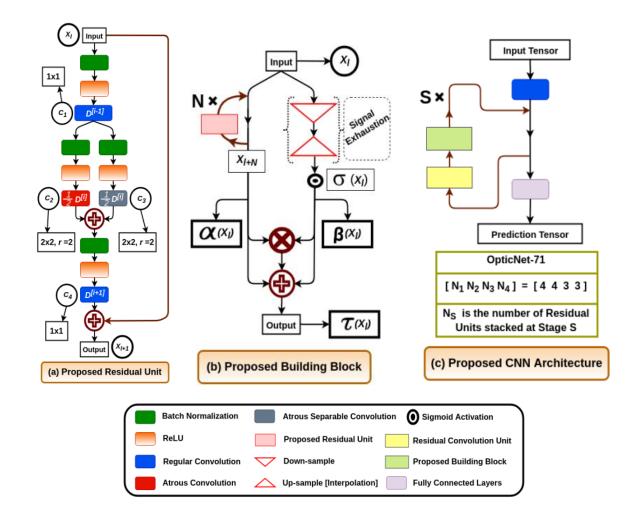
2.1) Prinsip dasar pengolahan sinyal/citra (yang dipelajari pada kuliah ini) yang diterapkan pada metode tsb

Prinsip yang digunakan pada penelitian ini adalah menggunakan algoritma CNN. Jadi gambar akan mengalami proses Konvolusi, Pooling, Interpolation dan lainnya. Semua proses tersebut terjadi didalam building block dan arsitektur bagian residual unit yang akan ditambilkan pada section Algoritma



2.2) Algoritma dan/atau alur kerja metode tsb

Flowchart dibawah ini merupakan arsitektur yang menjadi keterbaharuan paper ini, yaitu membangun arsitektur OpticNet. Arsitektur ini diharapkan dapat menyelesaikan permasalahan gradient explosion dan gradient degradation.



EKSPERIMEN DAN ANALISIS

1 DATA

[Jelaskan mengenai data yang digunakan, sumber data, jenis citra, dll]

Sumber dataset:

OCT 2017

Link : https://data.mendeley.com/datasets/rscbjbr9sj/3

Source : University of California San Diego, Guangzhou Women and Children's Medical Center

Srinivasan2014

Link : https://people.duke.edu/~sf59/Srinivasan BOE 2014 dataset.htm

Source : DUKE UNIVERSITY

Pengambilan gambar menggunakan alat citra beruuupa Optical Coherence Tomography (OCT) Scan Penelitian ini menggunakan 2 dataset yang dijalankan secara terpisah. Nama dari dataset yang pertama adalah OCT2017 dan yang kedua adalah Srinivasan2014. Dataset OCT2017 terdapat Kumpulan data ini berisi ribuan gambar OCT dan X-Ray Dada tervalidasi yang dideskripsikan dan dianalisis dalam "Identifying Medical Diagnoses and Treatable Diseases by Image-Based Deep Learning". Gambar dibagi menjadi satu set pelatihan dan satu set pengujian pasien independen. Gambar diberi label sebagai (penyakit)-(ID pasien acak)-(nomor gambar oleh pasien ini) dan dibagi menjadi 4 direktori: CNV, DME, DRUSEN, dan NORMAL. Sedangkan pada dataset Srinivasan2014 terdiri dari pemindaian volumetrik yang diperoleh dari 45 pasien: 15 pasien normal, 15 pasien dengan AMD kering, dan 15 pasien dengan DME menggunakan Spectralis SD-OCT

Jadi pada dataset OCT2017 terdapat gambar dengan 4 label, yaitu CNV, DME, DRUSEN, dan NORMAL dan pada dataset Srinivasan2014 terdapat 3 label, yaitu normal, DME, dan AMD.

2 KODE

[Jelaskan function-function utama yang dipakai, jelaskan perubahan yang ditambahkan pada kode (jika ada). Lampirkan kode pada file terpisah lengkap dengan data.]

DataLoader.py

```
from Environmental States and Control of English States (1992)

Francisco to the States (1992) (States (1992) (
```

Pada file ini terdapat 2 funtion yange namanya Kermany2018 dan Srinivasan2014. Kedua function memiliki tujuan yang sama, yaitu untuk me-load data, mengaugmentasi data yang tujuannya memperbanyak dataset, dan membagi data test dan train. Beda dari kedua function tersebut adalah function Kermany2018 untuk mengolah data OCT2017 sedangkan function Srinivasan2014 untuk mengolah data Srinivasan2014.

Metrics.py

```
print metric(y true, y pred, weighted error=False);
                                                                                                                                        cz = pycm.ConfusionMatrix(actual vector=y true.argmax(axis=1), predict vector=y pred.argmax(axis=1)
def Weighted_Error(y_true,y_pred):
                                                                                                                                        acc = cz.Overall_ACC
     matrix = confusion_matrix(y_true.argmax(axis=1), y_pred.argmax(axis=1))
                                                                                                                                        print("Average Accuracy : "+str(acc*100)+'%')
    matrix[[0,3],.] = matrix[[3,0],.]
matrix[:,[0,3]] = matrix[:,[3,0]]
matrix[[1,3],.] = matrix[[3,1],.]
matrix[:,[1,3]] = matrix[:,[3,1]]
                                                                                                                                       specificity = C2.1mc
totalprecision = 0
for key, value in specificity.items():
   totalprecision = totalprecision + value
   print('Average Specificity : '+str(totalprecision*100/4.0)+'%')
     matrix[[1,2],:] = matrix[[2,1],:]
matrix[:,[1,2]] = matrix[:,[2,1]]
     weighted\_error\_table = np.array([[0, 1 , 1, 1],[1,0,1,1],[4,2,0,1],[4,2,1,0]])
     weight_sum = 0
for i in range(4):
                                                                                                                                        totalrecall = 0
                                                                                                                                        for key, value in recall.items():
    totalrecall = totalrecall + value
print('Average Sensitivity : '+str(totalrecall*100/4.0)+'%')
           for j in range(4):
    if i!=j:
                       weight sum = weight sum + (matrix[i][j]*weighted error table[i][j])
                                                                                                                                       if weighted_error==True:
    Weighted_Error(y_true,y_pred)
     print ('Weighted Error : '+str(weight_sum*100/1000)+'%')
```

Pada file ini terdapat 2 function. Kedua function ini bertujuan untuk mengolah metric evaluasi. Pada function pertama mengolah metric evaluasi WeightedError. Pada function kedua functionya bertujuan untuk mengolah evaluasi metric Accuracy, S Specificity, dan Sensitivity.

Model.py

```
Heyert turns of the proof to th
```

Pada file model.py merupakan file yang bertujuan dalam pembangunan arsitektur CNN yang akan digunakan dalam klasifikasi penyakit retina yang diusung oleh peneliti, yaitu OpticNet. Contoh jika kita mencuplik pada gambar flowchart arsitektur dan sebagian kode yang ada di file model.py yang ditunjukan dibawah ini



Pada gambar diatas jelas bahwa input akan melewati batch normalization, kemudian activation layer, kemudian conv layer.

```
def OpticNet(input_size, num_of_classes):
    input_shape=(input_size, input_size, 3) # Height x Width x Channel
    X_input = Input(input_size)
    X = Conv2D(64, (7,7), strides=(2,2), padding='same', name ='CONV1', kernel_initializer=glorot_uniform(seed=0))(X_input)
    X = SatchNormalization(axis=-1, name ='BRLV1')(X)
    X = Artivation('relu', name ='RELUI')(X)
    X = res_conv(X, [64,64,256], 'RC81', 1)
    # MID 1
    X1 = EncoderDecoder(X, 'EncoderDecoder1')
    X2 = ROBI(X, [32,32,256], 'ROBI1',4)
    X = Multiply(name = 'Mutiply1')(XI,X2])
    X = res_conv(X, [128,128,512], 'RC1', 2)
    # MID 2
    X1 = EncoderDecoder(X, 'EncoderDecoder2')
    X2 = ROBI(X, [64,64,512], 'ROBI2',4)
    X = Multiply(name = 'Mutiply2')([XI,X2])
    X = Add(name = 'Add2')([X,XI,X2])
    X = Add(name = 'Add2')([X,XI,X2])
    X = res_conv(X, [256,256,1024], 'RC2', 2)
    # MID 3
    X1 = EncoderDecoder(X, 'EncoderDecoder3')
    X2 = ROBI(X, [128,128,1024], 'RD2', 2)
    # MID 3
    X1 = EncoderDecoder(X, 'EncoderDecoder3')
    X2 = ROBI(X, [128,128,1024], 'RD2', 2)
    # MID 3
    X1 = EncoderDecoder(X, 'EncoderDecoder3')
    X2 = ROBI(X, [128,128,1024], 'RD2', 2)
    # MID 3
    X1 = EncoderDecoder(X, 'EncoderDecoder3')
    X2 = ROBI(X, [128,128,1024], 'RD2', 2)
    # MID 3
    X1 = EncoderDecoder(X, 'EncoderDecoder3')
    X2 = ROBI(X, [128,128,1024], 'RD2', 2)
    # MID 3
    X1 = EncoderDecoder(X, 'EncoderDecoder3')
    X2 = ROBI(X, [128,128,1024], 'RD2', 2)
    # MID 3
    X1 = EncoderDecoder(X, 'EncoderDecoder3')
    X2 = ROBI(X, [128,128,1024], 'RD2', 2)
    X = ROBI(X, [128,128,1024], 'RD2', 2)
    X
```

```
# MID 4

X1 = EncoderDecoder(X, 'EncoderDecoder4')

X2 = RDBI(X, [256,256,2048], 'RDBI4',3)

X = Multiply(name = 'Mutiply4')([X1,X2])

X = Add(name = 'Add4')([X,X1,X2])

X = GlobalAveragePooling2D(name='global_avg_pool')(X)

X = Dense(256, name='Dense_1')(X)

X = Dense(num_of_classes, name='Dense_2')(X)

X = Activation('softmax', name='classifier')(X)

model = Model(inputs=X_input, outputs=X, name='')

model.compile(Adam(lr=.0001), loss='categorical_crossentropy', metrics=['accuracy'])

model.summary()

return model
```

Utils.py

Pada file ini terdapat 1 function yaitu callback_for_training. Function ini berfungsi untuk Menulis log TensorBoard setelah setiap kumpulan untuk memonitor metrik. Yang nantinya bisa di set untuk early stopping.

Visualize.py

```
import matplotlib.pyplot as plt
def plot_loss_acc(history,snapshot_name=None):
    loss = history.history['loss']
    val_loss = history.history['val_loss']
    epochs = range(len(loss))
    plt.plot(epochs, loss, 'bo')
    plt.plot(epochs, val_loss, 'g')
plt.title('Training and validation loss')
    plt.legend(['train', 'val'], loc='upper right')
    if snapshot_name == None:
        filename= 'OpticNet_loss.png'
        filename= snapshot_name+'_loss.png'
    plt.savefig(filename)
    plt.show()
    acc = history.history['acc']
    val_acc = history.history['val_acc']
    epochs = range(len(acc))
    plt.plot(epochs, acc, 'b')
    plt.plot(epochs, val_acc, 'g')
    plt.title('Training and validation accuracy')
    plt.legend(['train', 'val'], loc='lower right')
    if snapshot_name == None:
        filename= 'OpticNet_acc.png'
        filename= snapshot_name+'_acc.png'
    plt.savefig(filename)
    plt.show()
```

Pada file visualize.py terdapat function yang bertujuan untuk membuat grafik loss dan accuracy.

Train.py

```
Import target
from src.dialization sport termany2015, Scinivasm2014
from src.dialization sport termany2015, Scinivasm2014
from src.dialization sport defined:
sport target
sport target
from src.valization sport defined:
sport target
from src.valization sport call s
```

File ini bertujuan untuk mentraining data. Jika dataset yang sedang digunakan adalah OCT2017 maka akan memanggil function Kermany2018 yang berada di file dataloader.py . kemudian dilanjut dengan membersihkan session demi tujuan menyiapkan memory. Kemudian terdapat kode untuk memulai waktu dan memanggil function callback_for_training yang ada di file utils.py yang berguna untuk menyimpan model dan adaptive learning rate. Kemudian dilanjut dengan menload model dengan memanggil function yang ada di model.py. kemudian untuk mengolah metric evaluasi menggunakan kode pada file. Metrics.py. dan jika ingin membuat grafik menggunakan file visualize.py.

Test.py

```
import argparse
from keras.models import load_model
from keras.preprocessing.image import ImageDataGenerator
import keras.backend as K
from src.metrics import print metric
import time
def test(datadir,dataset,weights):
   test_datagen = ImageDataGenerator(rescale=1.0/255)
   image_size = 224
       classes=['AMD', 'DME', 'NORMAL']
       batch = 315
       test_batches = test_datagen.flow_from_directory(datadir, target_size=(image_size,image_size),color_mode='rgb', classes=classes,
       test_batches = test_datagen.flow_from_directory(datadir, target_size=(image_size,image_size),color_mode='rgb', classes=classes,
   imgs, y_true = next(test_batches)
   K.clear_session()
   model = load_model(weights)
   start= time.time()
   y_pred = model.predict(imgs)
   end = time.time()
   print ((end-start)/1000)
      print_metric(y_true,y_pred,weighted_error=False)
       print_metric(y_true,y_pred,weighted_error=True)
```

```
if __name__ == '__main__':
    parser = argparse.ArgumentParser()
    parser.add_argument('--dataset', type=str, required=True, help='Choosing between 2 OCT datasets', choices=['Srinivasan2014','Kermany2018'])
    parser.add_argument('--datadir', type=str, required=True, help='path/to/data_directory')
    parser.add_argument('--weights', type=str, required=True, help='Resuming training from previous weights')
    args = parser.parse_args()
    test(args.datadir, args.dataset, args.weights)
```

Ketika model sudah jadi, maka kita bisa menggunakan model tersebut untuk men-test data. Setelah men-load model terdapat kode untuk mem-predict image terhadap model tersebut. Kemudian untuk mengolah metric evaluasi menggunakan kode pada file. Metrics.py. dan jika ingin membuat grafik menggunakan file visualize.py.

3 HASIL, INTERPRETASI HASIL, ANALISIS

```
251/251 [============] - ETA: 0s - loss: 2.8066 - accuracy: 0.2625Traceback (most recent call last):
```

Setelah mengganti parameter kode

- Epoch 30 => 1
- jumlah data training >100000 data training => ±4000 data training
- jumlah data testing >10000 data training => ±400 data testing

didapat accuracy sebesar 0.26 dan loss sebesar 2.806.

Alasan mengapa saya mengganti parameter diatas adalah karena jika saya menggunakan parameter persis seperti yg dilakukan peneliti maka akan memakan waktu berhari hari untuk mentraining data nya. Dengan spesifikasi computer jauh diatas saya peneliti melakukan training selama 44 jam. Asumsi saya menggunakan computer saya adalah > 48 jam.

Alasan mengapa saya mendapat akurasi rendah dan loss yang cukup tinggi alasannya jelas karena saya mengubah jumlah dataset yang digunakan dan jumlah epoch yang saya gunakan sangat sedikit yaitu sebanyak 1 epoch. Jumlah dataset dan jumlah epoch tentu merupakan parameter yang sangat berpengaruh didalam dunia neural network.

4 ANALISIS TAMBAHAN

Terlebih dari hasil yang sangat bagus ketika dilakukan oleh peneliti, saya sedikit bisa menyimpulkan bahwa memerlukan komputasi yang sangat besar saat melakukan training dan saat saya mencoba model terhadap single file image. jadi spesifikasi device yang digunakan harus dalam keaadan optimal. Dan juga peneliti menyarankan memperluas pekerjaan ini untuk melakukan segmentasi batas lapisan retina, sehingga fitur dan kelainan yang lebih halus dapat dideteksi secara mandiri dengan kepastian yang lebih tinggi yang dapat menjadi alat potensial bagi dokter mata di seluruh dunia.

KESIMPULAN

Pada percobaan ini dapat disimpulkan bahwa Peneliti berhasil membuat model yang mengalahkan peforma model lain. Artinya keterbaharuan teknologi yang peneliti terapkan dalam penelitiannya dapat dibilang berhasil. Terbukti bahwa residual init, building block, cnn architecture berhasil meningkatkan peforma. Dengan akurasi sebesar 99.8 pada dataset Oct2017 dan akurasi sebesar 100.00 pada dataset Srinivasan2014 membuat intervensi ahli kurang dibutuhkan dikarenakan metric evaluasi yang didapat sudah sangat bagus.

REFERENS

- [1] C. for Disease Control, Prevention et al., "National diabetes statistics report, 2017," 2017.
- [2] J. W. Yau, S. L. Rogers, R. Kawasaki, E. L. Lamoureux, J. W. Kowalski, T. Bek, S.-J. Chen, J. M. Dekker, A. Fletcher, J. Grauslund et al., "Global prevalence and major risk factors of diabetic retinopathy," Diabetes care, vol. 35, no. 3, pp. 556–564, 2012.
- [3] D. S. W. Ting, G. C. M. Cheung, and T. Y. Wong, "Diabetic retinopathy: global prevalence, major risk factors, screening practices and public health challenges: a review," Clinical & experimental ophthalmology, vol. 44, no. 4, pp. 260–277, 2016.
- [4] R. R. Bourne, G. A. Stevens, R. A. White, J. L. Smith, S. R. Flaxman, H. Price, J. B. Jonas, J. Keeffe, J. Leasher, K. Naidoo et al., "Causes of vision loss worldwide, 1990–2010: a systematic analysis," The lancet global health, vol. 1, no. 6, pp. e339–e349, 2013.
- [5] P. P. Srinivasan, L. A. Kim, P. S. Mettu, S. W. Cousins, G. M. Comer, J. A. Izatt, and S. Farsiu, "Fully automated detection of diabetic macular edema and dry age-related macular degeneration from optical coherence tomography images," Biomedical optics express, vol. 5, no. 10, pp. 3568–3577, 2014.
- [6] K. Alsaih, G. Lemaitre, M. Rastgoo, J. Massich, D. Sidibe, and F. Meri- 'audeau, "Machine learning techniques for diabetic macular edema (dme) classification on sd-oct images," Biomedical engineering online, vol. 16, no. 1, p. 68, 2017.
- [7] D. S. Friedman, B. J. OColmain, B. Munoz, S. C. Tomany, C. McCarty, P. De Jong, B. Nemesure, P. Mitchell, J. Kempen et al., "Prevalence of age-related macular degeneration in the united states," Arch ophthalmol, vol. 122, no. 4, pp. 564–572, 2004.

- [8] N. Ferrara, "Vascular endothelial growth factor and agerelated macular degeneration: from basic science to therapy," Nature medicine, vol. 16, no. 10, p. 1107, 2010.
- [9] W. L. Wong, X. Su, X. Li, C. M. G. Cheung, R. Klein, C.-Y. Cheng, and T. Y. Wong, "Global prevalence of age-related macular degeneration and disease burden projection for 2020 and 2040: a systematic review and meta-analysis," The Lancet Global Health, vol. 2, no. 2, pp. e106–e116, 2014.
- [10] D. S. Kermany, M. Goldbaum, W. Cai, C. C. Valentim, H. Liang, S. L. Baxter, A. McKeown, G. Yang, X. Wu, F. Yan et al., "Identifying medical diagnoses and treatable diseases by image-based deep learning," Cell, vol. 172, no. 5, pp. 1122–1131, 2018.
- [11] H. Nguyen, A. Roychoudhry, and A. Shannon, "Classification of diabetic retinopathy lesions from stereoscopic fundus images," in Proceedings of the 19th Annual International Conference of the IEEE Engineering in Medicine and Biology Society.'Magnificent Milestones and Emerging Opportunities in Medical Engineering'(Cat. No. 97CH36136), vol. 1. IEEE, 1997, pp. 426–428.
- [12] B. M. Ege, O. K. Hejlesen, O. V. Larsen, K. Møller, B. Jennings, D. Kerr, and D. A. Cavan, "Screening for diabetic retinopathy using computer based image analysis and statistical classification," Computer methods and programs in biomedicine, vol. 62, no. 3, pp. 165–175, 2000.
- [13] G. Panozzo, B. Parolini, E. Gusson, A. Mercanti, S. Pinackatt, G. Bertoldo, and S. Pignatto, "Diabetic macular edema: an oct-based classification," in Seminars in ophthalmology, vol. 19, no. 1-2. Taylor & Francis, 2004, pp. 13–20.
- [14] C. I. Sanchez, R. Hornero, M. I. Lopez, and J. Poza, "Retinal image analysis to detect and quantify lesions

- associated with diabetic retinopathy," in The 26th Annual International Conference of the IEEE Engineering in Medicine and Biology Society, vol. 1. IEEE, 2004, pp. 1624–1627.
- [15] R. A. Costa, M. Skaf, L. A. Melo Jr, D. Calucci, J. A. Cardillo, J. C. Castro, D. Huang, and M. Wojtkowski, "Retinal assessment using optical coherence tomography," Progress in retinal and eye research, vol. 25, no. 3, pp. 325–353, 2006.
- [16] X. C. MeindertNiemeijer, L. Z. K. Lee, M. D. Abramoff, and M. Sonka, `"3d segmentation of fluid-associated abnormalities in retinal oct: Probability constrained graph-search-graph-cut," IEEE Transactions on Medical Imaging, vol. 31, no. 8, pp. 1521-1531, 2012.
- [17] A. Lang, A. Carass, M. Hauser, E. S. Sotirchos, P. A. Calabresi, H. S. Ying, and J. L. Prince, "Retinal layer segmentation of macular oct images using boundary classification," Biomedical optics express, vol. 4, no. 7, pp. 1133–1152, 2013.
- [18] A. Mishra, A. Wong, K. Bizheva, and D. A. Clausi, "Intraretinal layer segmentation in optical coherence tomography images," Optics express, vol. 17, no. 26, pp. 23 719–23 728, 2009.
- [19] G. Quellec, K. Lee, M. Dolejsi, M. K. Garvin, M. D. Abramoff, and M. Sonka, "Three-dimensional analysis of retinal layer texture: identification of fluid-filled regions in sd-oct of the macula," IEEE transactions on medical imaging, vol. 29, no. 6, pp. 1321–1330, 2010.
- [20] K. Lee, M. Niemeijer, M. K. Garvin, Y. H. Kwon, M. Sonka, and M. D. Abramoff, "Segmentation of the optic disc in 3-d oct scans of the optic nerve head," IEEE transactions on medical imaging, vol. 29, no. 1, pp. 159–168, 2010.
- [21] I. Ghorbel, F. Rossant, I. Bloch, S. Tick, and M. Paques, "Automated segmentation of macular layers in oct images and quantitative evaluation of performances," Pattern Recognition, vol. 44, no. 8, pp. 1590–1603, 2011.
- [22] R. Kafieh, H. Rabbani, and S. Kermani, "A review of algorithms for segmentation of optical coherence tomography from retina," Journal of medical signals and sensors, vol. 3, no. 1, p. 45, 2013.
- [23] J. Y. Lee, S. J. Chiu, P. P. Srinivasan, J. A. Izatt, C. A. Toth, S. Farsiu, and G. J. Jaffe, "Fully automatic software for retinal thickness in eyes with diabetic macular edema from images acquired by cirrus and spectralis systems," Investigative ophthalmology & visual science, vol. 54, no. 12, pp. 7595–7602, 2013.

- [24] G. Lemaître, M. Rastgoo, J. Massich, C. Y. Cheung, T. Y. Wong, E. Lamoureux, D. Milea, F. Meriaudeau, and D. Sidibé, "Classification" of sd-oct volumes using local binary patterns: experimental validation for dme detection," Journal of ophthalmology, vol. 2016, 2016.
- [25] C. S. Lee, D. M. Baughman, and A. Y. Lee, "Deep learning is effective for classifying normal versus agerelated macular degeneration oct images," Ophthalmology Retina, vol. 1, no. 4, pp. 322–327, 2017.
- [26] M. Treder, J. L. Lauermann, and N. Eter, "Automated detection of exudative age-related macular degeneration in spectral domain optical coherence tomography using deep learning," Graefe's Archive for Clinical and Experimental Ophthalmology, vol. 256, no. 2, pp. 259–265, 2018.
- [27] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," arXiv preprint arXiv:1409.1556, 2014.
- [28] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in Proceedings of the IEEE conference on computer vision and pattern recognition, 2016, pp. 770–778.
- [29] K. He, X. Zhang, S. Ren, and J. Sun, "Identity mappings in deep residual networks," in European conference on computer vision. Springer, 2016, pp. 630–645.
- [30] L. Sifre and S. Mallat, "Rigid-motion scattering for image classification," PhD thesis, Ph. D. thesis, vol. 1, p. 3, 2014.
- [31] F. Wang, M. Jiang, C. Qian, S. Yang, C. Li, H. Zhang, X. Wang, and X. Tang, "Residual attention network for image classification," in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017, pp. 3156–3164.
- [32] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "Mobilenetv2: Inverted residuals and linear bottlenecks," in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018, pp. 4510–4520.
- [33] F. Chollet, "Xception: Deep learning with depthwise separable convolutions," in Proceedings of the IEEE conference on computer vision and pattern recognition, 2017, pp. 1251–1258.
- [34] M. Awais, H. Muller, T. B. Tang, and F. Meriaudeau, "Classification" of sd-oct images using a deep learning approach," in 2017 IEEE International Conference on Signal and Image Processing Applications (ICSIPA). IEEE, 2017, pp. 489–492.

[35] S. P. K. Karri, D. Chakraborty, and J. Chatterjee, "Transfer learning based classification of optical coherence tomography images with diabetic macular edema and dry age-related macular degeneration," Biomedical optics express, vol. 8, no. 2, pp. 579–592, 2017.

[36] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein et al., "Imagenet large scale visual recognition challenge," International journal of computer vision, vol. 115, no. 3, pp. 211–252, 2015